

1. Énoncé du Problème Commercial

Une grande entreprise de vente au détail souhaite mieux comprendre le comportement d'achat de ses clients afin d'améliorer les ventes, la satisfaction client et la fidélité à long terme. L'équipe de gestion a remarqué des changements dans les habitudes d'achat selon les segments démographiques, les catégories de produits et les canaux de vente (en ligne vs. en magasin). Elle s'intéresse particulièrement à l'identification des facteurs — tels que les remises, les avis, les saisons ou les préférences de paiement — qui influencent les décisions d'achat et les achats répétés.

Vous êtes chargé d'analyser le jeu de données sur le comportement des consommateurs de l'entreprise afin de répondre à la question commerciale suivante :

«Comment l'entreprise peut-elle exploiter les données d'achat des consommateurs pour identifier des tendances, améliorer l'engagement client et optimiser les stratégies marketing et produits ? »

2. Livrables du Projet

1. **Préparation et modélisation des données (Python)** : Nettoyer et transformer le jeu de données brut pour l'analyse.
2. **Analyse de données (SQL)** : Organiser les données en un format structuré, simuler des transactions commerciales et exécuter des requêtes pour extraire des insights sur les segments clients, la fidélité et les facteurs d'achat.
3. **Visualisation et insights (Power BI)** : Construire un tableau de bord interactif mettant en évidence les motifs et tendances clés, permettant aux parties prenantes de prendre des décisions basées sur les données.
4. **Rapport et présentation** : Rédiger un rapport de projet clair résumant les conclusions principales et les recommandations commerciales. Préparer une présentation qui communique visuellement les insights et recommandations actionnables aux parties prenantes.

3. Vue d'ensemble du projet

Ce projet analyse le comportement d'achat des clients en utilisant les données transactionnelles provenant de 3 900 achats dans différentes catégories de produits. L'objectif est de révéler des insights sur les modèles de dépense, les segments de clients, les préférences produits et le comportement d'abonnement, afin de guider les décisions stratégiques de l'entreprise.

4. Résumé du jeu de données

Nombre de lignes : 3 900

Nombre de colonnes : 18

Principales caractéristiques :

Démographie des clients : Âge, Sexe, Localisation, Statut d'abonnement

Détails des achats : Article acheté, Catégorie, Montant d'achat, Saison, Taille, Couleur

Comportement d'achat : Remise appliquée, Code promo utilisé, Achats précédents, Fréquence des achats, Note des avis, Type de livraison

Données manquantes : 37 valeurs dans la colonne "Review Rating"

5. Analyse exploratoire des données avec Python

Nous avons commencé par la préparation et le nettoyage des données en Python :

- **Chargement des données:** Importation du jeu de données avec **pandas**.
- **Exploration initiale:** Utilisation de **df.info ()** pour vérifier la structure et de **describe()** pour obtenir les statistiques résumées.

	Customer ID	Age	Gender	Item Purchased	Category	Purchase Amount (USD)	Location	Size	Color	Season	Review Rating	Subscription Status	Shipping Type	Discount Applied	Promo Code Used
count	3900.000000	3900.000000	3900	3900	3900	3900.000000	3900	3900	3900	3900	3863.000000	3900	3900	3900	3900
unique	NaN	NaN	2	25	4	NaN	50	4	25	4	NaN	2	6	2	2
top	NaN	NaN	Male	Blouse	Clothing	NaN	Montana	M	Olive	Spring	NaN	No	Free Shipping	No	No
freq	NaN	NaN	2652	171	1737	NaN	96	1755	177	999	NaN	2847	675	2223	2223
mean	1950.500000	44.068462	NaN	NaN	NaN	59.764359	NaN	NaN	NaN	NaN	3.750065	NaN	NaN	NaN	NaN
std	1125.977353	15.207589	NaN	NaN	NaN	23.685392	NaN	NaN	NaN	NaN	0.716983	NaN	NaN	NaN	NaN
min	1.000000	18.000000	NaN	NaN	NaN	20.000000	NaN	NaN	NaN	NaN	2.500000	NaN	NaN	NaN	NaN
25%	975.750000	31.000000	NaN	NaN	NaN	39.000000	NaN	NaN	NaN	NaN	3.100000	NaN	NaN	NaN	NaN
50%	1950.500000	44.000000	NaN	NaN	NaN	60.000000	NaN	NaN	NaN	NaN	3.800000	NaN	NaN	NaN	NaN
75%	2925.250000	57.000000	NaN	NaN	NaN	81.000000	NaN	NaN	NaN	NaN	4.400000	NaN	NaN	NaN	NaN
max	3900.000000	70.000000	NaN	NaN	NaN	100.000000	NaN	NaN	NaN	NaN	5.000000	NaN	NaN	NaN	NaN

Previous Purchases	Payment Method	Frequency of Purchases
3900.000000	3900	3900
NaN	6	7
NaN	PayPal	Every 3 Months
NaN	677	584
25.351538	NaN	NaN
14.447125	NaN	NaN
1.000000	NaN	NaN
13.000000	NaN	NaN
25.000000	NaN	NaN
38.000000	NaN	NaN
50.000000	NaN	NaN

- **Gestion des données manquantes:** Vérification des valeurs nulles et imputation des valeurs manquantes dans la colonne **Review Rating** en utilisant la médiane de chaque catégorie de produit.
- **Standardisation des colonnes:** Renommage des colonnes au format **snake_case** pour une meilleure lisibilité et documentation.
- **Feature Engineering :**
 - Création de la colonne **age_group** en regroupant les âges des clients.
 - Création de la colonne **purchase_frequency_days** à partir des données d'achat.
- **Vérification de la cohérence des données:** Vérification de la redondance entre **discount_applied** et **promo_code_used** ; suppression de la colonne **promo_code_used**.
- **Intégration à la base de données:** Connexion du script Python à MySQL et chargement du DataFrame nettoyé dans la base pour l'analyse SQL.

6. Analyse des données avec SQL (Transactions commerciales)

Nous avons réalisé une analyse structurée dans MySQL pour répondre aux principales questions commerciales :

1. **Chiffre d'affaires par sexe:** Comparaison du chiffre d'affaires total généré par les clients masculins et féminins.

	gender	revenue
▶	Male	157890
	Female	75191

2. **Clients dépensant beaucoup malgré une remise :** Identification des clients ayant utilisé des remises mais ayant dépensé plus que le montant moyen d'achat.

	customer_id	purchase_amount
▶	2	64
	3	73
	4	90
	7	85
	9	97

customer 5 × ! Read Only

Output

Action Output

#	Time	Action	Message
✓ 1	15:07:16	SELECT customer_id, purchase_amount from ...	839 row(s) returned

- 3. Top 5 des produits par note:** Identification des produits ayant la meilleure note moyenne.

	item_purchased	Average Product Rating
►	Gloves	3.86
	Sandals	3.84
	Boots	3.82
	Hat	3.8
	Skirt	3.78

- 4. Comparaison par type de livraison:** Comparaison des montants moyens d'achat entre la livraison Standard et Express.

	shipping_type	ROUND(AVG(purchase_amount),2)
►	Express	60.48
	Standard	58.46

- 5. Abonnés vs non abonnés:** Comparaison de la dépense moyenne et du chiffre d'affaires total selon le statut d'abonnement.

	subscription_status	total_customers	avg_spend	total_revenue
►	Yes	1053	59.49	62645
	No	2847	59.87	170436

- 6. Produits dépendants des remises:** Identification des 5 produits ayant le pourcentage le plus élevé d'achats avec remise.

	item_purchased	discount_rate
►	Hat	50.00
	Sneakers	49.66
	Coat	49.07
	Sweater	48.17
	Pants	47.37

- 7. Segmentation des clients :** Classification des clients en segments Nouveaux, Récurrents et Fidèles selon l'historique des achats.

	customer_segment	Number of customers
►	Loyal	3116
	Returning	701
	New	83

- 8. Top 3 des produits par catégorie :** Liste des produits les plus achetés dans chaque catégorie.

	item_rank	category	item_purchased	total_orders
►	1	Accessories	Jewelry	171
	2	Accessories	Sunglasses	161
	3	Accessories	Belt	161
	1	Clothing	Blouse	171
	2	Clothing	Pants	171
	3	Clothing	Shirt	169
	1	Footwear	Sandals	160
	2	Footwear	Shoes	150
	3	Footwear	Sneakers	145
	1	Outerwear	Jacket	163
	2	Outerwear	Coat	161

- 9. Acheteurs récurrents et abonnements:** Vérification si les clients ayant plus de 5 achats sont plus susceptibles de s'abonner.


	subscription_status	repeat_buyers
►	Yes	958
	No	2518

- 10. Chiffre d'affaires par tranche d'âge:** Calcul de la contribution totale au chiffre d'affaires de chaque groupe d'âge.

	age_group	total_revenue
►	Young Adult	62143
	Middle-aged	59197
	Adult	55978
	Senior	55763

7. Tableau de bord dans Power BI

Enfin, nous avons créé un tableau de bord interactif dans Power BI pour présenter les insights de manière visuelle.



8. Recommandations Business

- **Augmenter les abonnements** – Promouvoir des avantages exclusifs réservés aux abonnés.
- **Programmes de fidélité** – Récompenser les clients qui effectuent des achats répétés afin de les faire évoluer vers le segment « Loyal ».
- **Révision de la politique de réduction** – Trouver un équilibre entre l'augmentation des ventes et la maîtrise des marges.
- **Positionnement produit** – Mettre en avant, dans les campagnes marketing, les produits les mieux notés et les plus vendus.
- **Marketing ciblé** – Concentrer les efforts sur les tranches d'âge générant le plus de revenus et les utilisateurs d'expédition express.